


Trabajo Práctico N°4

Aprendizaje No Supervisado



Grupo 7:

- ❖ Andres Podgorny
- ❖ Hugo Lichtenberger
- ❖ Ouss Slaitane
- ❖ Nicolás Birsá
- ❖ Valentin Ye Li

Ej1 Países europeos




Consigna

Dada una lista de 28 países de Europa con datos de cada país correspondientes a sus características económicas, sociales y geográficas, se busca

- Estudiar su asociación usando Kohonen **(1.A)**
- Analizar las componentes principales usando Oja **(1.B)**



1.A Modelo de Kohonen



Variación del radio y eta

Se parte de un valor inicial, para luego reducirlos a lo largo de las ejecuciones hasta aproximarse a un valor final cercano al mínimo aceptable.

$$\eta(i) = \eta_0 \frac{N - i}{N} \quad \text{siendo } \eta(0) < 1$$


$$r(i) = r_0 + (1 - r_0) \frac{i}{N}$$

con


$N = \text{Número de iteraciones}$

$i = \text{Iteración actual}$

Pesos aleatorios




Pesos del input



$r_0=1.8$ | $\eta_0=0.9$ | Grilla 4x4 | 500 épocas

Distancias entre neuronas vecinas



$\eta_0=0.9$




$r_0=1.8$

500 épocas

Grilla 4x4

Con pesos iniciales del input

Promedio de las variables



$$\eta_0=0.9$$

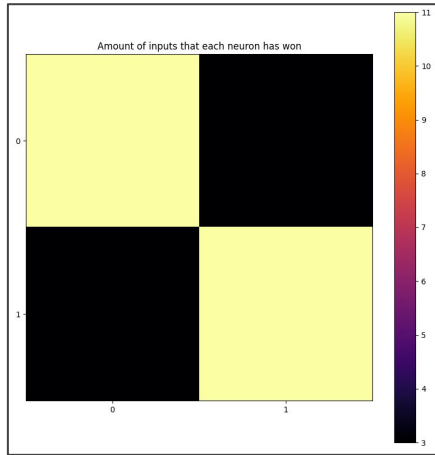
$$r_0=1.8$$

500 épocas

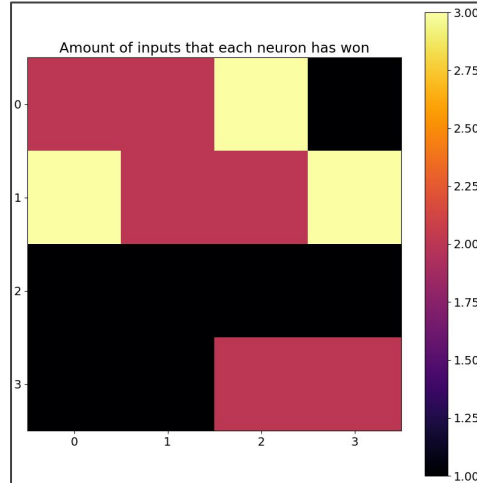
Grilla 4x4

Con pesos iniciales del input

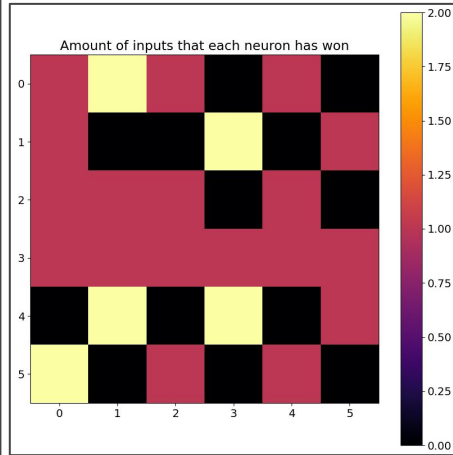
Tamaño de la grilla



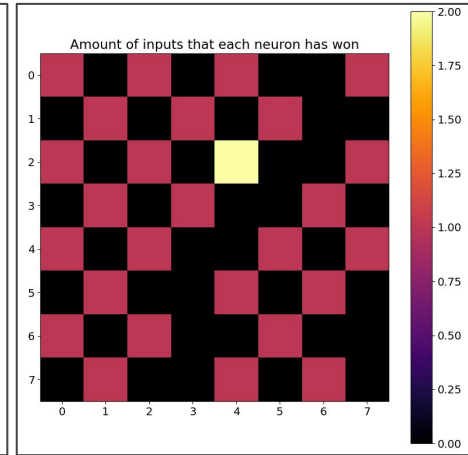
2x2



4x4



6x6



8x8

$\eta_0 = 0.9$
 $r_0 = 1.8$
500 épocas
Con pesos iniciales del input

Para 2x2 hay un aglutinamiento de países en 2 neuronas, mientras que con 6x6 apenas se pueden agrupar países de a pares con varias neuronas muertas.


4x4 es un buen balance entre ambos casos.

Conclusiones

- Para el caso analizado, un tamaño de grilla **4x4** logra agrupar países con características similares sin caer en que éstos estén o muy juntos o muy dispersos.
- Inicializar la grilla con valores iniciales no asegura que, al finalizar el algoritmo, no hayan neuronas muertas.



1.B Oja

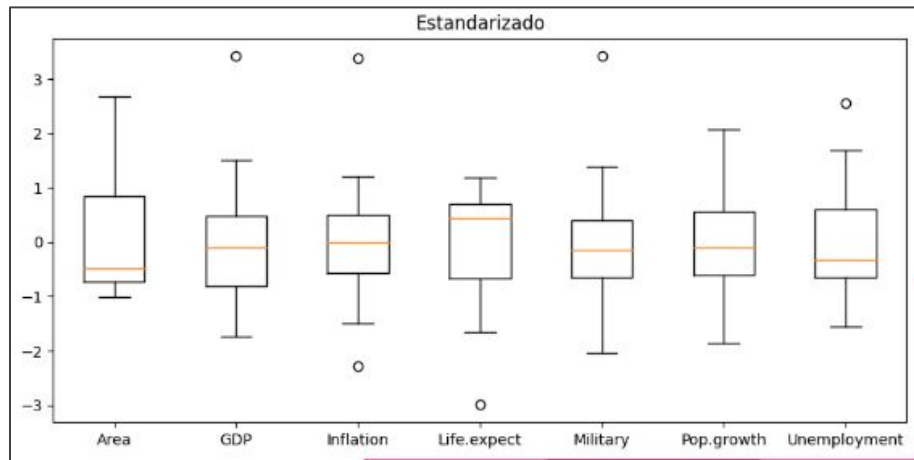



$$y(\mathbf{x}) = \sum_{j=1}^m x_j w_j$$


$$\Delta \mathbf{w} = \mathbf{w}_{n+1} - \mathbf{w}_n = \eta y_n (\mathbf{x}_n - y_n \mathbf{w}_n)$$

SKLearn

Variables con y sin estandarización



SKLearn




Valores con Oja y Sklearn

VARIABLE	OJA	SKLEARN
INFLATION	0.407222	0.406518
UNEMPLOYMENT	0.271308	0.271656
MILITARY	0.187514	0.188112
ÁREA	0.125589	0.124874
POPULATION GROWTH	-0.475552	-0.475704
LIFE EXPECTANCY	-0.483021	-0.482873
GDP	-0.500443	-0.500506

learning rate: 0.0001 epochs: 10000


Oja

PCA1 per country using Oja



SKLearn


PCA1 per country using Sklearn



Cambio en la tasa de aprendizaje

1000 épocas
Promedio de 5
ejecuciones


El error comparado
con Sklearn



Conclusiones

- Importante estandarizar el dataset
- Tasa de aprendizaje influye mucho en los resultados





2. Hopfield

Consigna

Construir letras del abecedario usando $\{-1, 1\}$ con matrices de **5x5**, e implementar el método de Hopfield para asociar matrices de consulta, generalmente con ruido, con patrones de letras almacenados.

$$\begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ -1 & -1 & -1 & 1 & -1 \\ -1 & -1 & -1 & 1 & -1 \\ 1 & -1 & -1 & 1 & -1 \\ 1 & 1 & 1 & -1 & -1 \end{pmatrix}$$

Matriz

$$\begin{matrix} * & * & * & * & * \\ & & & * & \\ & & & * & \\ * & & & * & \\ * & * & * & & \end{matrix}$$

Patrón



Estructura de estado

Se guardan **4** patrones de letras en la red de *Hopfield* de acuerdo a la **regla del 15%**, excepto cuando se pruebe qué pasa variando este valor.

Estas letras se almacenan como vectores de **25** posiciones con los mismos valores $\{-1, 1\}$, y se usan para calcular la ortogonalidad entre patrones.



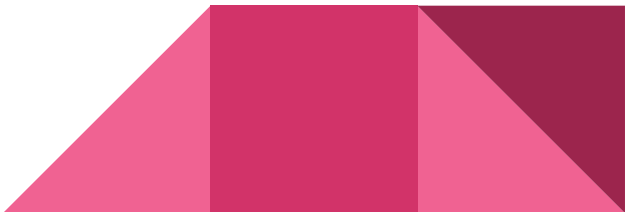
Métrica de ortogonalidad

Ya que ningún conjunto de letras resultaba puramente ortogonal, usamos un **score** para medir la ortogonalidad de dicho conjunto, donde:

$$score(\{a, b, c, d\}) = |a * b| + |a * c| + |a * d| + |b * c| + |b * d| + |c * d|$$

En este caso, mientras **menor sea el score, más ortogonal será el conjunto** y, por ende, mejores resultados con Hopfield.

También lo usaremos para comparar vectores *muy ortogonales* con otros *poco ortogonales*, y sus diferencias en resultados.

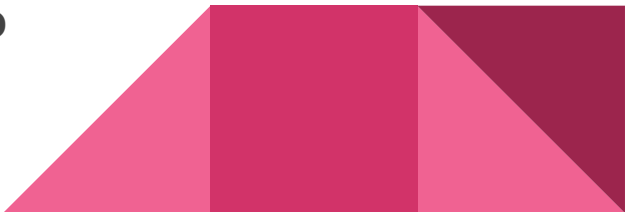


Conjuntos de prueba

Para los análisis a realizar se usaron 3 conjuntos de letras, cada uno representativo de un nivel de ortogonalidad según el score usado:


- **[G, R, T, V]** -> score: 6 (el más ortogonal)
- **[O, Q, T, X]** -> score: 58 (“algo” ortogonal)
- **[A, F, P, R]** -> score: 110 (el menos ortogonal)

Además, sus consultas sin ruido (de letras del conjunto) son:

- Ortogonal: todas correctas
 - “Algo” ortogonal: **O,Q -> Q | T -> T | X -> espúreo**
 - Menos ortogonal: todas devuelven **P**
- 

Ejemplos de consultas


Conjunto ortogonal **[G, R, T, V]**



Estados espúreos


Más ortogonal

[G, R, T, V]



“Algo” ortogonal

[O, Q, T, X]




Nada ortogonal

[A, F, P, R]




Ruido - Exactitud



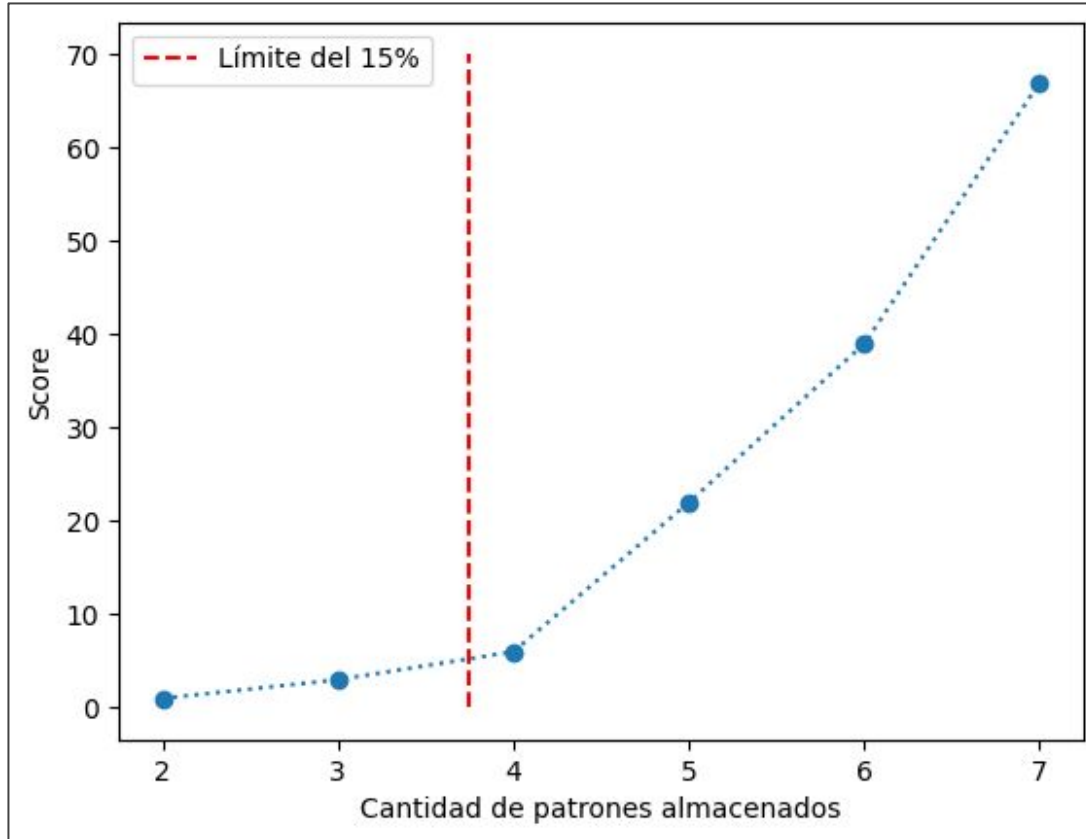
40 realizaciones por valor y conjunto, con 10 por letra

Ruido - “Falsos positivos”



40 realizaciones por valor y conjunto, con 10 por letra

Cantidad de patrones

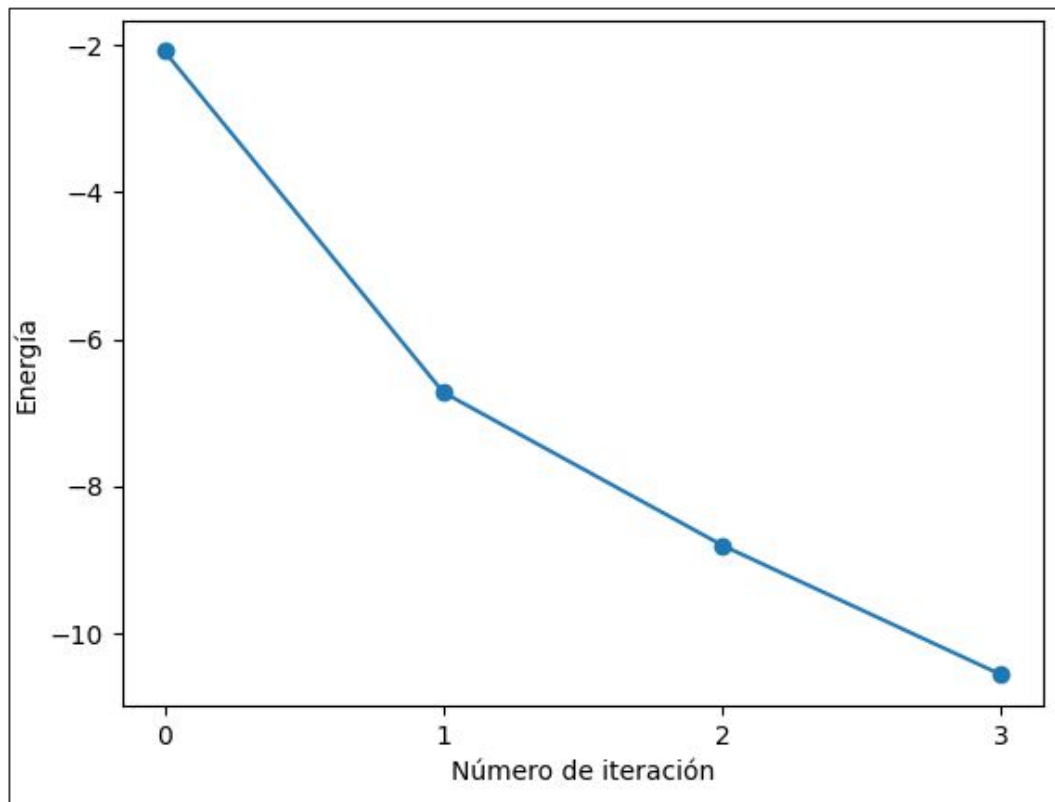


Se usa el conjunto más ortogonal para cada tamaño de conjunto.


El conjunto es relativamente ortogonal para tamaños menores o cercanos a la regla del 15%.

Luego, el score de ortogonalidad se dispara, cayendo en los casos antes vistos de baja ortogonalidad.

Función de energía



Más ortogonal
[G, R, T, V]



Letra G con 30% de ruido

Conclusiones

- La presencia de estados espúreos es independiente de la ortogonalidad del conjunto.
- El modelo es susceptible al ruido, siendo mayor este efecto mientras más ortogonal sea el conjunto usado.
- En el caso estudiado, sobrepasar el límite teórico de 15% significa no poder encontrar conjuntos *relativamente* ortogonales.





¡Gracias!